

音声技術今昔物語

ボコーダーから大規模モデルまで — Speech Technology Then and Now

篠崎 隆宏（東京科学大学） ・ 大谷 大和（情報通信研究機構）

SESSION / 講演番号

1-Q-2



Web デモ

- ① 連結管シンセ
- ② 声から声道モデル
- ③ DTW で認識

tttllab.github.io/asj90-speech-demo

「人間らしさ」の象徴だった音声。その歴史は、少しずつ機械に置き換えられてきた物語である。

発声器官は**機械**として模倣され、声道は**音響管**として計算され、波形から**パラメータ**が推定される。発話は**確率的な時系列**として認識され、いまや音声は大規模モデルが扱う**トークン列・潜在表現**へ。

人間に固有と思われた **発声・聴取・分析・認識・生成・対話** という営みが、一つずつ切り出され、機械化されてきた。

発声

聴取


分析

認識

生成

対話

技術の系譜 MAJOR MILESTONES IN SPEECH TECHNOLOGY



1 機械式発話装置から音声入出力へ

- ・ **Kempelen の発話装置 (1791)**：ふいご＝肺、リード＝声帯、可変共鳴部＝声道。人の発声をまるごと機械で組み立てた最初期の試み。
- ・ **Radio Rex (1920s)**：呼び声の音響的な共振で犬が飛び出す玩具。“声で機械を動かす”という発想の原点（単語認識ではない）。
- ・ **Dudley の Vocoder (1939, Bell Labs)**：音声を少数の制御情報へ分析し、受信側で再合成。**VODER** はその合成側を人間が“演奏”した公開デモ。


こぼれ話

ケンペレンには“詐欺師”の顔も——チェス自動人形 The Turk の中には人が隠れていた（右図）。Vocoder は軍の**秘話（暗号）通信**に使われ、のちに Kraftwerk・YMO のロボットボイスへ。Vocoder の音は音楽の中でもいまも現役。

参考動画（QR）：CBCテレビ公式チャンネル youtu.be/6EnAGy1lIWU



Kempelen 発話装置の複製 — F. Brackhane (Quintesson), Public domain, via Wikimedia Commons / 実演動画(QR) youtube.com/watch?v=k_YUB_S6Gpo



The Turk の内部図解 — Racknitz, 1789, Public domain, via Wikimedia Commons

18世紀後半 – 1930年代

帯域圧縮・秘話通信のために



VODER＝合成側を手手で“演奏”

1939年 NY万博でVODERを公開デモ

Vocoder の分析再合成

2 声道を測り、声道を推定する — 反射係数が貫く一本の糸

- ・ **測る**：X線、いまは実時間MRI（右上の映像）で発話中の声道形状を観測し、断面積関数へ。
- ・ **Kelly–Lochbaum**：声道＝断面積 S_m の管の連結。境界の反射・透過で音の伝搬を計算する。
- ・ **推定する**＝ **LPC（板倉・斎藤）**：X線なしで、波形そのものから声道特性へ。全極モデル $H(z)=1/A(z)$ 。
- ・ **PARCOR / LSP(板倉)**：量子化に強く、低ビットレート符号化を実現。携帯電話音声の礎に。

$$R_m = (S_m - S_{m-1}) / (S_m + S_{m-1}) \quad \cdots \text{断面積の差／和が境界の反射係数}$$
$$k_m = -R_m$$

添字 m は唇側が 1、声門側が P（境界の数＝フィルタの段数）


こぼれ話

計算機が初めて歌った“Daisy Bell”（IBM 704, Bell Labs）。これを見た A. C. クラークの着想で、『2001年宇宙の旅』の **HAL 9000** は停止間際にこの歌を歌う。

日本発の系譜：声道研究の原点『The Vowel』（千葉・梶山, 1941）も、低ビットレート符号化を切り拓いた板倉の **PARCOR / LSP** も、この学会の歴史とともにある。



千葉・梶山(1941)が測定した声道形状に基づき作成された実体模型（荒井, 2001）




声道は動く：X線からMRIへ——舌・唇・軟口蓋が作る「管の形」の変化が、そのまま母音・子音を作る。（動画はQRから）

Max Planck Inst. (Frahm group) 公式動画： youtube.com/watch?v=6dAEE7FYQfc



発話中の声道の実時間MRI（動画より1コマを切り出し） — © Biomedizinische NMR Forschungs GmbH, CC BY-SA 3.0, via Wikimedia Commons





3つの境界 $R_3, R_2, R_1 = 3$ 段 k_3, k_2, k_1 （縦の位置も対応）

連結音響管 と PARCOR 合成フィルタ $1/A(z)$ — 境界と段が 1 対 1 に対応

3 時系列モデルとしての音声

1970 – 2000年代

- ・ **DTW**：動的計画法で時間伸縮を許して照合。テンプレートと“歩幅を合わせて”比べる。強化学習の Bellman 方程式と同じく、Bellman の動的計画法が共通の土台。
- ・ **HMM**：音声＝隠れ状態列から生成される観測列。連続音声認識を初めて体系化。
- ・ **合成側**：篠崎モデル（韻律）・波形接続・HMM 音声合成。人手設計から“データに基づく学習”への橋渡し。




DTW の最適経路 と left-to-right HMM

4 特徴量設計から表現学習へ

2010年代 – 2020年代前半

- ・ **end-to-end 認識**：GMM-HMM → DNN。CTC/RNN-T を経て、Transformer(2017) が認識・合成に共通の基盤に。人手設計の特徴量が学習される表現へ置き換わる。
- ・ **WaveNet**：波形そのものを確率モデルで生成 → ニューラルボコーダ。「ボコーダー」の意味が分析再合成器から波形生成器へ変遷。
- ・ **SSL**：ラベルなし音声から表現を学習。音声＝潜在表現・離散トークンに。大規模モデル時代の入口。



SSL：隠したトークンを文脈から予測

隠して当てる（SSL）→ 認識・合成が同じ表現でつながる

5 音声言語モデルと相互作用する音声へ

2020年代 – 現在

- ・ **従来の対話**：ASR → 理解 → 生成 → TTS の直列パイプライン。交互にしか話せない half-duplex 的な振る舞い。
- ・ **音声LLM**：SSL の離散トークンを大規模言語モデルが直接扱う——テキストを介さず、音声のまま理解・生成する流れへ。
- ・ **Moshi などの full-duplex 音声LLM**：聞きながら話す・相槌・割り込み・待つ——会話の時間構造そのものをモデル化（デモ動画はQRから）
- ・ 音声は媒体を超え、**対話状態を更新し関係を調整する信号** へ。

評価軸が変わる：認識率・合成品質 だけでなく ↓

発話権の管理

相槌・割り込みのタイミング

韻律の手がかり




Moshi の対話デモ——聞きながら話す full-duplex のふるまい
Kyutai 公式チャンネル youtu.be/hm2lJSKcYvo

half-duplex（交互にしか話せない）



full-duplex（重なりながら話す）




時間軸で見る：交互（half）と重なり（full）

おわりに — 何が残るか

- ・ **機械化されたもの**：発声・聴取・分析・認識・生成——そして対話の時間構造まで。
- ・ **残っているもの**：韻律・声質・間・相槌——記号化しにくい表層の現象。
- ・ **その背後にあるもの**：感情、身体、そして「なぜその一言を言うのか」という発話の動機。声は身体から出て、誰かに向けられる。

それらも記述され尽くしたとき、「話す」に固有のものは残るのか。——残ると考えたいのは、我々の願いか。



人と機械が、声とともに働く

